Лабораторная работа №6

Тема: Моделирование таблиц хеширования;

Цель работы: освоение навыков построения и проверки таблиц хеширования.

Краткие теоретические сведения

Назначение и применение таблиц хеширования

Таблицы хеширования применяются для обеспечения программного поиска информации по содержанию специального ключевого слова или фрагмента (части) самих данных.

Основные понятия

Для формирования таблиц хеширования используются следующие компоненты и понятия:

ID – ключевое слово (любое имя, слово, сочетание любых символов и т.д.) или его идентификатор;

V – числовое значение ключевого слова;

h (V) – хеш-адрес, вычисленный по числовому значению V ключевого слова;

B – начальный адрес таблицы (величина кратная размеру строки таблицы);

H – общее количество строк (ячеек) в таблице.

Способы перевода ключевых слов в числовые значения и преобразование их в хеш-адреса рассмотрены в [9] и на лекции по теме 11.

Напомним, что при совпадении хеш-адресов, вычисленных по разным ключевым словам, возникает коллизия (конфликт). В этом случае для размещения второй и последующих записей необходимо использовать резервные ячейки памяти, которые размещаются либо в самой таблице хеширования (внутренняя адресация), либо в специальной области памяти (области переполнения).

Для поиска свободных резервных ячеек при внутренней адресации применяется процедура пробинга (линейного, квадратичного или случайного).

Структура ячейки (строки) хеш-таблицы

В состав ячейки (строки) хеш-таблицы должны входить:

– ключевое слово (ID) или его идентификатор;

– соответствующие этому ключу данные или указатели;

– различные флажки (признаки).

Формат ячейки (строки) хеш-таблицы приведен на рисунке 1.

ID	C	U	T	L	D	Po	Данные или указатели (Pi)

Рисунок 1. Формат ячейки (строки) хеш-таблицы

Обозначения на рисунке 1[9]:

ID – идентификатор ключевого слова или само ключевое слово (K),

C – флажок коллизий,

U – флажок «занято»,

T – терминальный флажок,

L – флажок связи, указывающий, что находится в поле Pi – данные или указатель(адрес), где находятся данные;

D – флажок вычеркивания,
Po – указатель области переполнения (или следующей записи в цепочке),
Pi – данные или указатель области данных.

Рассмотрим пример построения хеш-таблицы.

Построим хеш-таблицу в соответствии с приведенными ниже исходными данными.

Справочные данные о группе или подгруппе студентов (не менее 10 человек), включающие:

1) фамилии студентов
2) любые данные (например, имя, увлечения(спорт,искусство)).

Ключевое слово – фамилия студента.

Примечание: могут быть использованы другие ключевые слова, например, набор предметов, перечень специальностей и т. д.

Решение

1. Применим седующий способ определения значения ключевого слова (V) по его первым двум буквам:
   - используем русский алфавит;
   - буквам присваиваются соответствующие номера:

   А=0, Б=1, ... , Я=32, т. е. всего 33 номера. Будем эту величину считать основанием позиционной системы счисления, тогда сочетание двух первых букв фамилии (ключевого слова), можно записать, например, следующим образом:

   а) Вяткин V[Вя] = $2 \cdot 33^1 + 32 \cdot 33^0 = 98$

   б) Третьяк V[Тр] = $19 \cdot 33^1 + 17 \cdot 33^0 = 644$.

   Аналогично может быть использован латинский алфавит.
2. Структура ячейки (строки) хеш-таблицы и ее размер определяется в соответствии с исходными данными и форматом ячейки (см. Рисунок 1).
3. Спасоб формирования хеш-адреса определяется размером таблицы и вычисленным значением V (например, h(V)=V · mod H + B, где V · mod H – остаток от деления V на H).

   Способы обработки коллизий:

   - размещение резервных ячеек в хеш-таблице (внутренняя адресация);
   - использование области переполнения.

   Способ (вид) пробинга при выборе резервных ячеек при использовании внутренней адресации – линейный.

   Вариант хеш-таблицы некоторой условной группы студентов приведен в таблице 1, эта таблица состоит из двух частей:

   а) правая часть – это собственно хеш-таблица;

   б) левая часть, вкючающая фамилии студентов, расположенные в порядке записи строк в хеш-таблицу, вычисленные значения V и h для каждого ключевого слова (фамилии студента).

   Размер таблицы H=20 строк.

   Начальный адрес таблицы B=0 (можно взять любое другое значение, но оно не вляет на постороение хеш-таблицы, а только на расположение таблицы в памяти).

Таблица 1.

Левая часть			Правая часть (ТХ)								
Фамилия студента	V	h	№ строки ТХ	Значение полей и флажков ТХ							
				ID	C	U	T	L	D	P_0	P_i (данные)
1.Абаев (ID1)	1	1	0	ID6	1	1	1	0	0	2	Сергей
2.Бобков (ID2)	48	18	1	ID1		1	1	0	0		Тимур
3.Видерт (ID3)	75	15	2	ID7	0	1	0	0	0	3	Евгений
4.Гракова (ID4)	116	16	3	ID8		1	0	0	0	12	Иван
5.Кожевников (ID5)	388	18	4	ID12		1	1	0	0		Максим
6.Ковалев (ID6)	378	18	5								
7.Крикунов (ID7)	380	0	6								
8.Кот (ID8)	378	18	7								
9.Давыденко (ID9)	132	12	8	ID13	0	1	1	0	0		Александр
10.Горбань (ID10)	114	14	9								
11.Данилов (ID11)	132	12	10								
12.Козлов (ID12)	378	18	11								
13.Азимов (ID13)	8	8	12	ID9	1	1	0	0	0	13	Ирина
			13	ID11		1	1	0	0		Павел
			14	ID10		1		0	0		Петр
			15	ID3		1		0	0		Руслан
			16	ID4		1		0	0		Наталья
			17								
			18	ID2	1	1	0	0	0	19	Андрей
			19	ID5	0	1	1	0	0	00	Константин

Примечание: В графе «ID» правой части таблицы записываются полное ключевое слово (фамилия) соответствующая индексу ID_i (1-20).

Напомним, что с хеш-таблицей можно выполнять различные операции, в частности, поиск информации по ключевому слову, запись в таблицу новых строк, удаление отдельных строк из таблицы. Правила и выполнения таких операций подробно рассмотрели в части «Теория ЭРУД АОИС» (Тема 11, подразделы 11.1-11.3)

Кратко напомним только операцию удаления.

Удаление строк из хеш-таблицы производиться следующим образом:

1. По ключевому слову удаляемой строки определяется ее хеш-адрес(h), отыскивается в ТХ эта строка и в ней устанавливается флажок D в «1».

2. Анализируется состояние флажков T и C, содержимое поля P_0 и определяется какая это строка – одиночная (т.е не является частью цепочки строк(ячеек), сформированных из-за возникших при формировании таблицы коллизий), последняя строка цепочки или любая другая строка в цепочке. Выполнить это можно следующим образом:

а) если состояние флажка T=1 и в поле P_0 записан адрес этой же строки (h), то эта строка является одиночной и ее можно просто удалить, сделать свободным, т.е. установить флажок U в «0»

б) если состояние флажка T=1 и в поле P_0 записан какой-то код, указывающий, что эта строка в ходит в цепочку резервных ячеек, то эта строка является конечной в какой-то цепочке. В этом случае отслеживается предыдущая относительно удаляемой строки в цепочке путем сравнения содержимого поля P_0 всех предыдущих строк с адресом удаляемой строки h и далее:

- удаляемая строка делается свободной (флажок U устанавливается в 0, значение остальных полей и флажков может быть произвольным)
- в найденной предыдущей строке, у коротой значения поля P_0 = h удаляемой строки, флажок T устанавливается в «1».

в) Если состояние флажка T=0 и содержание поля $P_0 \neq h_{\text{уд}}$, то удаляемая строка является другой строкой (не последней) в цепочке резервных ячеек. В этом случае находится последующая за удаляемой строкой в этой цепочке по содержимому поля P_0 и эта строка переписывается на место удаляемой и делается свободной, т.е. в ней устанавливается флажок U в «0», фактически удаляется не вычисление по хеш-адресу строки, а следующее за ней, при этом содержимое остальных строк этой цепочки не изменяется.

г) если состояние флажка T=0, а C=1, то эта строка является первой в цепочке, начинающейся с хеш-адреса $h_{\text{уд}}$ удаляемой строки. В этом случае по содержимому поля P_0остлеживается следующая за удаляемой строка, её содержимое переписывается в удаляемую, в ней устанавливается C=1, и эта строка делается свободной (U=0).

Контрольные вопросы:

1. Для чего спользуются таблицы хеширования?
2. Что используется для программного поиска информации по содержанию?
3. Назовите основные функции хештрования.
4. Приведите структуру хеш-таблицы.
5. Приведите способы перевода ключевых слов в числовые значения.
6. Приведите способы преобразования числового значения ключевого слова в хеш-адрес.
7. Что такое коллизия? В каких случаях она возникает?
8. Назовите способы обработки коллизий.
9. В каких случаях производится процедура пробинга?

Индивидуальные задания:

1. Разработать и проверить программу, обеспечивающую формирование хеш-таблицы, по ключевым словам и выполнение различных операций с этой таблицей – включение в таблицу новых строк, поиск информации в таблице по ключевым словам, удаление строк из таблицы.
2. Хеш-таблица должна быть разработана по образцу примера, рассмотренного выше.
3. Хеш-таблица должна быть тематической, т.е. все ключевые слова и данные должны быть из определенной отрасли науки, техники или деятельности людей. Перечень вариантов тематической направленности хеш-таблицы приведен в таблице 2.

   Таблица 2.

№ варианта	Тематическая направленность (ТХ)	Ключевые слова (ID)	Данные (P_i)
1	Математика	Названия, термины, понятия из соответствующей отрасли науки, техники, деятельности.	Определение, что это или из какого раздела данной науки, техники и т.д. это ключевое слово.
2	Физика		
3	География		
4	Биология		
5	Грамматика		
6	Литература		
7	Медицина		
8	Транспорт		
9	Спорт		
0	Армия, вооружение		

4. Каждый студент выполняет вариант хеш-таблицы, номер которого совпадает с последней цифрой номера записи его фамилии в списке группы.

   Примечание: если у студента доставшийся ему вариант хеш-таблицы вызывает затруднее, например, из-за недостатка знаний в данной тематике, он может предложить и по согласованию с преподавателем выполнить свой другой вариант, отсутствующий в таблице 2 с соблюдением всех требований к построению хеш-таблиц, приведенных в данном методическом материале.
5. При выполнение любого варианта ЛР №6 должны быть выполнены слудующие требовония:

   - размер таблицы не менее 20 строк;
   - количество записанных в таблице строк – не менее 10-ти;
   - количество коллизий не менее 2-х;
   - количество строк, объединенных в цепочки резервных ячеек, сформированных из-за коллизий – не менее 3-х;
   - размер и структура каждой строки хеш-таблицы должны быть одинаковыми и постоянными.

   Примечание: если размер поля P_i в хеш-таблице не позволяет записать все данные по конкретному ключевому слову, может быть использована отдельная область памяти для записи этих данных, при этом в поле P_i записывается указатель, где в памяти находятся данные, и флажок «L» (флажок связи) устанавливается в «1».

Требовония к программе:

1. Разработаная программа должна уметь выполнять следующие функции:
   - определение числовых значений ключевых слов (V);
   - формирование хеш-адресов [h(v)];
   - формирование самой хеш-таблицы, в соответствии со структурой, приведенной на рисунке 1;
   - обработку коллизии (т.е. обеспечение нахождения резервных ячеек и запись в них);
   - выборку из хеш-таблицы необходимой информации по соответствующему ключевому слову;
   - занесение в хеш-таблицу новых новых записей по новым ключевым словам;
   - удаление из хеш-таблицы отдельных записей;
   - контроль за потыткой записи в хеш-таблицу информации по ключевому слову, уже имеющемуся в таблице;
   - расчет коэффициентов заполнения хеш-таблицы.
2. Программа должна обеспечивать индикацию (вывод на экран) содержимого всех полей и указателей всех строк хеш-таблицы, вычисленных значений V(K) и h(V) для каждой записи, коэффициента заполнения хеш-таблицы.

Методика выполнения:

1. Определяется перечень ключевых слов и данных для записи в таблицу.
2. Определяется структура и размер строк таблицы.
3. Строится программа выполняющая:
   - формирование хеш-таблицы;
   - формирование хеш-адресов;
   - занесение (запись) в таблицу записей (строк);
   - обработку коллизий;
   - поиск записей в хеш-таблице по задонному ключевому слову;
   - удаление записей (строк) из хеш-таблицы;
   - контроль за коррекностью использования ключевых слов (каждое ключевое слово может быть использовано только для одной записи);
   - индикацию вычисленных для каждого ключевого слова числового значения и хеш-адреса.

Стандартная процедура проверки разработанной программы заключается в анализе результатов выполнения предъявленных к ней требований.